

# Лекция 12: AI Agents и Tools

От text generation към действия

# Цели на лекцията

- От генериране към действия — защо agents?
- Архитектура на агенти — компоненти и loops
- ReAct — reasoning + acting
- Memory — как агентите помнят
- Planning и reflection — самокорекция
- Multi-agent системи
- Реални резултати и ограничения

# Част 1: От Generation към Action

# Ограничението на чистата генерация


User: Какво е времето в София днес?

LLM: Не мога да проверя текущото време,  
тъй като нямам достъп до интернет.


## Моделът може само да генерира текст

- Няма достъп до интернет
- Няма достъп до файлове
- Няма възможност за изчисления
- Няма възможност за действия

# Какво ако моделът можеше...




# Agent Paradigm



**Agent = LLM + Tools + Loop**

# Кратка история




# Защо 2023-2024 беше експозия на agents?

1. По-способни модели — следват сложни инструкции
2. Function calling — built-in API за tools
3. По-дълъг context — помнят повече
4. По-добър reasoning — правят по-малко грешки

Но: Все още не са reliable в production

## Част 2: Agent Architecture

# Основни компоненти



# Agent Loop

1. Perception
  - └ Receive input, observe results
2. Reasoning
  - └ LLM decides what to do
3. Action
  - └ Execute chosen tool
4. Observation
  - └ Get tool result, loop back to 1

# Tool Definitions

```
tools = [
  {
    "name": "search",
    "description": "Search the web for information",
    "parameters": {
      "query": {
        "type": "string",
        "description": "Search query"
      }
    }
  },
  {
    "name": "calculator",
    "description": "Perform math calculations",
    "parameters": {
      "expression": {"type": "string"}
    }
  }
]
```

# Как моделът избира tool?

User: Колко е 15% от 847?

LLM reasoning:


- Трябва математическо изчисление
- Имам calculator tool
- Expression: "847 \* 0.15"

LLM output:

```
{  
    "tool": "calculator",  
    "parameters": {"expression": "847 * 0.15"}  
}
```

Моделът "разбира" кога кой tool е подходящ

# Parsing и Error Handling



# Пример: Simple Agent

User: Какво е населението на България и колко е 5% от него?

Agent:

Thought: Нужна ми е информация за населението

Action: search("население на България 2024")

Observation: ~6.5 miliona duши

Thought: Сега да изчисля 5%

Action: calculator("6500000 \* 0.05")

Observation: 325000

Answer: България има ~6.5 miliona жители.

5% от това са 325,000 души.

## Част 3: ReAct Pattern

# Какво е ReAct?

Reasoning + Acting

Стандартен agent:

User → Action → Observation → Action → Answer

ReAct agent:

User → Thought → Action → Observation →  
→ Thought → Action → Observation → Answer

**Ключова разлика:** Explicit reasoning преди всяко действие

# ReAct структура

Question: Кой е режисьорът на филма, спечелил  
Оскар 2024 за най-добър филм?

Thought: Трябва да намеря кой филм спечели Оскар 2024

Action: search("Оскар 2024 най-добър филм")

Observation: "Oppenheimer" спечели Оскар за най-добър филм

Thought: Сега трябва да намеря режисьора

Action: search("Oppenheimer режисьор")

Observation: Christopher Nolan

Thought: Имам отговора

Answer: Christopher Nolan

# Защо Thought помага?

Без Thought:

```
Action: search("Оскар 2024 режисьор") ← грешен query
```

С Thought:

Thought: Въпросът има две части:

- 1) Кой фильм спечели
  - 2) Кой е режисьорът
- Първо да намеря филма...

```
Action: search("Оскар 2024 най-добър филм") ← правилен query
```

# ReAct vs Chain-of-Thought

CoT	ReAct
Reasoning в текст	Reasoning + Actions
Един изход	Много стъпки
Само модел knowledge	+ External knowledge
Може да hallucinate	Grounded в observations

**ReAct = CoT + Tool Use + Grounding**

# Кога ReAct помага?

Помага:

- Multi-step въпроси
- Нужда от актуална информация
- Комбиниране на източници
- Verification на факти

Не помага:

- Прости въпроси
- Creative tasks
- Когато няма подходящи tools

# ReAct Failure Modes

## 1. Wrong tool selection:

Thought: Да потърся...

Action: calculator("население България") ← грешен tool

## 2. Reasoning loop:

Thought: Да проверя отново...

Action: search(same query)

Thought: Да проверя пак... [∞]

## 3. Observation misinterpretation:

Observation: "6.5 million (2021 estimate)"

Thought: Населението е 6.5 ← miss-ва годината

# Част 4: Agent Memory


# Context Window ограничение

Context Window (~128K tokens)

System prompt  
Tool definitions  
Conversation history    ← Расте!  
Current task

Проблем: history > context → губим начало

# Types of Memory



# Short-term Memory

Какво включва:

- Текущ conversation
- Последни N съобщения
- Working context за текущата задача

Стратегии:

1. Sliding window: Keep last N messages
2. Token budget: Keep until X tokens
3. Summarize old: Compress older messages

# Long-term Memory

Какво включва:

- Facts научени от потребителя
- Минали разговори (summarized)
- Важни документи

Implementation:

User: Казвам се Иван, работя като програмист

Agent → Memory store:

```
{  
  "fact": "User name is Иван",  
  "category": "personal"  
}  
{  
  "fact": "User works as programmer",  
  "category": "personal"  
}
```

# Memory Retrieval

New message: "Помниш ли какво ти казах за проекта?"



Query memory store



Retrieve relevant facts:

- "User working on ML project"
- "Deadline is January 15"



Add to context before LLM call

# Episodic vs Semantic Memory

Episodic	Semantic
Конкретни събития	Общи факти
"Вчера говорихме за X"	"User предпочита Python"
Time-stamped	Без timestamp
Raw conversation	Extracted knowledge

**Практика:** Повечето agents използват и двете

# Memory Management

Conversation grows...



[Summary] + [Recent messages]

= Компресирана история + детайлен контекст

## Част 5: Planning и Reflection

# Защо Planning?

Task: "Напиши блог пост за машинно обучение,  
добави изображения и публикувай"


Без planning:

Agent веднага започва да пише → забравя images

С planning:

1. Напиши draft
  2. Генерирай/намери images
  3. Review и edit
  4. Публикувай
- Следва структуриран план

# Plan-and-Execute Pattern



# Reflection: Самокритика

Agent output: "Столицата на Австралия е Сидни"



Reflection prompt: "Провери верността на отговора"




Reflection: "Грешка: Столицата е Канбера, не Сидни"



Corrected: "Столицата на Австралия е Канбера"

# Reflexion Pattern



Reflexion = Learn from mistakes

# Self-Correction Loop

```
def solve_with_reflection(task, max_attempts=3):
    for attempt in range(max_attempts):
        solution = agent.solve(task)

        critique = agent.reflect(
            f"Провери това решение: {solution}"
        )

        if "correct" in critique.lower():
            return solution

    task = f"{task}\nПредишна грешка: {critique}"

return solution # Best effort
```

# Предизвикателството

**Проблем:** Моделът не знае какво не знае

Agent: "Населението на България е 8 милиона"

Reflection: "Това звуци правилно" ← грешно!

**Reflection работи по-добре за:**

- Логически грешки
- Format violations
- Incomplete answers

**Не толкова за:**

- Factual errors (без external verification)

## Част 6: Tools in Practice

# Common Tool Categories

Категория	Примери	Use Case
Search	Web, Wikipedia	Information retrieval
Code	Python, SQL	Calculations, data
Files	Read, Write	Document processing
APIs	Weather, Stocks	Real-time data
Browser	Navigate, Click	Web automation

# Tool Design Principles

Добър tool:

```
{  
    "name": "get_weather",  
    "description": "Get current weather for a city",  
    "parameters": {  
        "city": {"type": "string", "required": True},  
        "units": {"type": "string", "enum": ["celsius", "fahrenheit"]}  
    }  
}
```

Лош tool:

```
{  
    "name": "do_stuff", # Неясно име  
    "description": "Does things", # Неясно описание  
    "parameters": {} # Липсват параметри  
}
```

# Tool Selection at Scale

Problem: 100+ tools → Model confused

Solutions:

1. Tool retrieval:

Query → Embed → Find relevant tools → Use only those

2. Hierarchical tools:

"Category: Data" → "Subcategory: SQL" → Specific tools

3. Tool recommendation:

Few-shot examples of which tool for which task

# Code Interpreters

User: "Анализирай този CSV файл"

Agent generates:

```
import pandas as pd  
df = pd.read_csv('data.csv')  
print(df.describe())
```

Sandbox execution

Return results

# Security Considerations

## SECURITY

- ✗ Arbitrary code execution
- ✗ File system access without limits
- ✗ Network requests to anywhere
- ✗ Credential exposure
  
- ✓ Sandboxed environments
- ✓ Whitelisted tools only
- ✓ Rate limiting
- ✓ Input validation
- ✓ Output sanitization


# Част 7: Multi-Agent Systems

# Защо повече от един agent?

Single agent:



Multi-agent:




vs


Ползи: Специализация, diverse perspectives, debate

# Multi-Agent Architectures


## 1. Hierarchical:



## 2. Peer-to-peer:



# Debate Architecture




# Practical Examples

Coding assistant:



Research team:



# Coordination Challenges

Challenge	Problem	Mitigation
Communication	Agents misunderstand each other	Clear protocols
Overhead	Many LLM calls	Efficient routing
Conflicts	Disagreements	Resolution rules
Loops	Infinite back-and-forth	Max iterations

**Reality:** Multi-agent добавя complexity за marginal gains

## Част 8: Results и Limitations

# Benchmarks

Benchmark	Measures	Top Performance
SWE-bench	Code fixes	~50% (verified)
WebArena	Web tasks	~35%
GAIA	General assistant	~70% (Level 1)

**Note:** Numbers change fast, top models improve monthly

## Къде Agents успяват

- ✓ Structured tasks with clear tools  
"Search for X, summarize results"
- ✓ Well-defined workflows  
"Parse this PDF, extract tables"
- ✓ Code generation with feedback  
"Write code, run tests, fix errors"
- ✓ Information synthesis  
"Research topic from multiple sources"

# Къде Agents се провалят

- ✗ Long-horizon planning  
Error accumulates over many steps
- ✗ Ambiguous tasks  
"Make this better" → unclear actions
- ✗ Recovery from errors  
One mistake → cascade of failures
- ✗ Novel situations  
No training data for new tools

# The Reliability Problem

Single step accuracy: 95%

Multi-step task (10 steps):

$$0.95^{10} = 59.8\% \text{ success rate}$$

Multi-step task (20 steps):

$$0.95^{20} = 35.8\% \text{ success rate}$$

Малки грешки се натрупват експоненциално

# Cost и Latency

Simple query:

1 LLM call  $\times \$0.01 = \$0.01$ , 1 second

Agent task (20 tool uses):

$\sim 40 \text{ LLM calls} \times \$0.01 = \$0.40$ , 60+ seconds

Metric	Simple LLM	Agent
Cost	1x	10-50x
Latency	1s	30s-5min
Reliability	High	Medium-Low

# Demo vs Production Gap

Demo:

- Cherry-picked examples
- Controlled env
- Ideal tools
- Clean data

Works !

Production:

- Any user input
- Edge cases
- Tool failures
- Messy data

vs

Often breaks

# Обобщение

# Ключови идеи


1. **Agents** = LLM + Tools + Loop → действия в света
2. **ReAct** = Reasoning + Acting → по-добър tool selection
3. **Memory** = Short-term + Long-term → дълги interactions
4. **Planning** = Decompose tasks → структуриран подход
5. **Reflection** = Self-critique → самокорекция (ограничена)
6. **Multi-agent** = Специализация → complexity trade-off
7. **Reality** = Capable but unreliable → use carefully

# Course Arc


Lectures 1–4:



Lectures 5–6:



Lectures 7–9:



Lectures 10–12:



# What's Next for the Field?

Today:

Capable but  
unreliable

Good at demos,  
brittle in prod

Human oversight  
required

Tomorrow:


More reliable  
agents

Good in  
production

More autonomous  
systems



# Практически Framework



# Ресурси

## Papers:

- Yao et al. (2022) — ReAct
- Shinn et al. (2023) — Reflexion
- Park et al. (2023) — Generative Agents
- Wang et al. (2024) — Survey of LLM-based Agents

## Tools:

- LangChain, LlamaIndex — Agent frameworks
- Claude MCP — Tool integration
- OpenAI Assistants API

**Въпроси?**